VISÃO COMPUTACIONAL · ENTREGA FINAL

Avaliação de danos em edificações a partir de imagens de satélite

Segmentação semântica de pares pré/pós-desastre do xBD com uma U-Net siamesa

Tulio Castro · novembro de 2026
github.com/Tulio-CS/Disaster-Damage



predição do modelo final · Palu, 2018 (split de teste)

Depois de um desastre, onde estão os prédios atingidos?

- Resgate, abrigo e logística dependem de saber onde há edificações atingidas e quão graves são os danos
- Levantar isso à mão sobre imagens de satélite leva dias, e a resposta não pode esperar
- O xBD / xView2 formalizou a tarefa: um par de imagens da mesma área, antes e depois do evento

PERGUNTA

Uma rede neural consegue localizar as edificações e graduar o dano de cada uma a partir do par pré/pós, bem o bastante para apoiar a triagem, inclusive em um desastre que não viu no treino?

11.034

pares de cenas 1024×1024, pré e pós

19

desastres de 6 tipos: furacão, enchente, incêndio, terremoto, tsunami, vulcão

850.736

edificações anotadas com nível de dano

Segmentação semântica em 5 classes, a partir de duas datas



imagem pré



imagem pós



anotação



predição do modelo

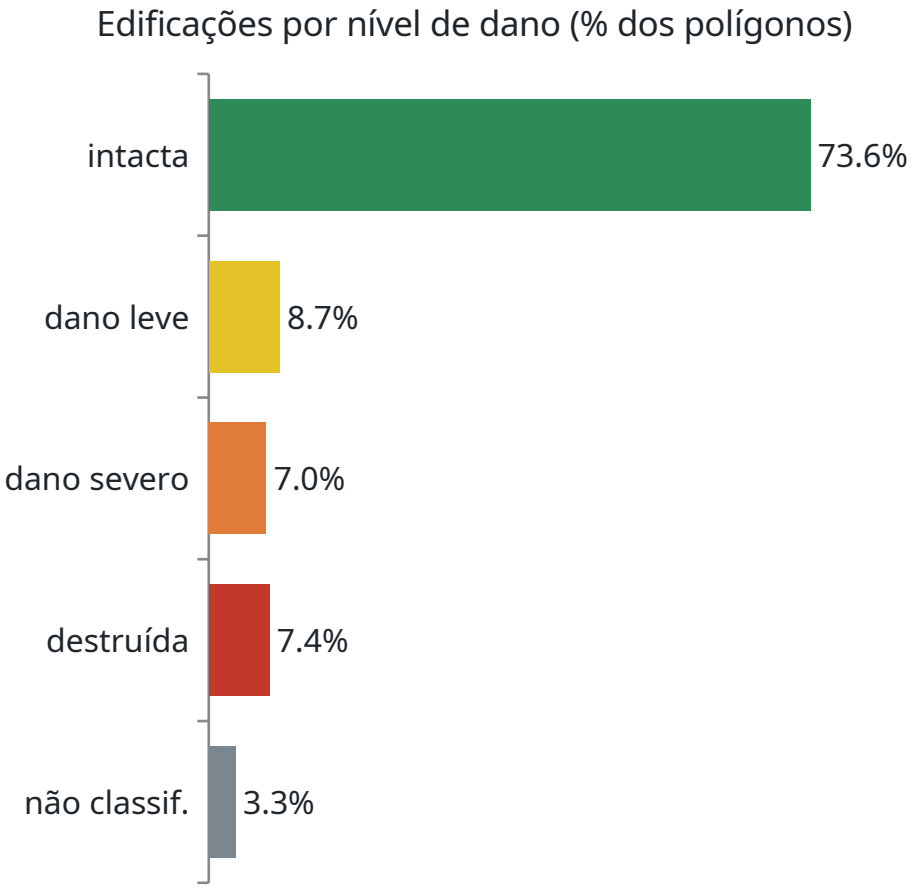
classes por pixel: fundo · intacta · dano leve · dano severo · destruída

Métrica oficial do xView2: `score = 0,3 · F1 localização + 0,7 · F1 dano` (F1 dano = média harmônica dos F1 das 4 severidades; F1 por pixel = Dice)

Split oficial do xView2, com o teste guardado para o fim

split	cenas	eventos	papel
tier1	2.799	10	treino
tier3	6.369	9	treino
hold	933	10	validação: escolhe a época e o modelo
test	933	10	teste: usado só na avaliação final

- Controle de generalização: 5 folds agrupados por desastre, sem nenhum evento dos dois lados
- Desbalanceamento: 97% dos pixels são fundo e 35% das cenas não têm nenhuma edificação
- 156 cenas de teste têm cópia idêntica no treino (socal-fire = woolsey-fire): o teste é reportado com e sem elas



Do GeoTIFF bruto ao lote: cada etapa decidida por medição

1

Conversão

GeoTIFF int16 → PNG uint8, sem perda (139 → 33 GB)

2

Máscara

polígonos rasterizados; un-classified vira “ignorar”

3

Normalização

média e desvio por canal medidos no xBD, não os do ImageNet

4

Augmentação

geométrica igual em pré e pós; fotométrica independente em cada data

5

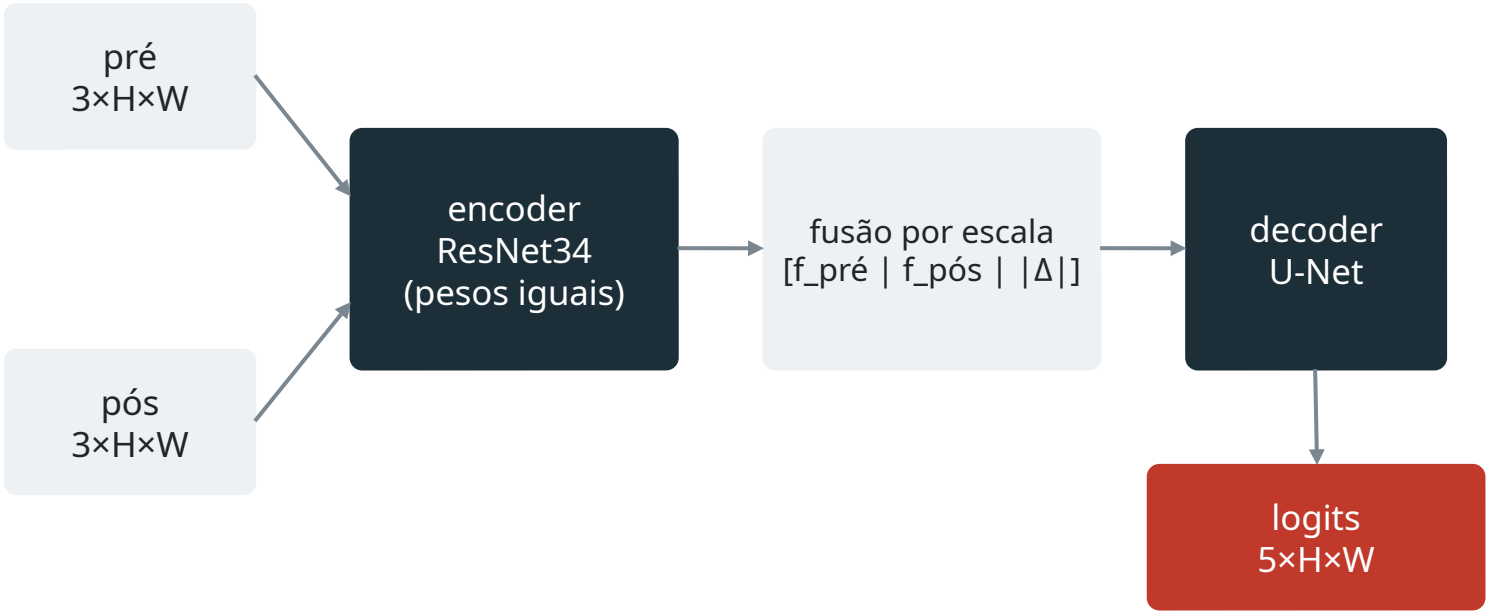
Amostragem

cenas com dano ×3, cenas vazias ×0,25; recorte de 512 px no treino

Cuidados contra vazamento de dados

- Divisão determinística pela pasta de origem, sem sorteio; o notebook 02 testa que nenhuma cena atravessa os splits
- Constantes de normalização e augmentação só do treino; validação e teste recebem apenas normalização
- Auditoria por hash de pixel: duplicatas entre eventos removidas do treino e agrupadas no mesmo fold

Baseline: U-Net siamesa com encoder ResNet34



Parâmetros	25,5 M (21,3 M no encoder)
Saída	logits 5×H×W → argmax por pixel
Perda	Focal + Dice (dano, pesos por classe) + BCE + Dice (localização)
Otimizador	AdamW, weight decay 1e-4, clip de gradiente 1,0
Taxa de aprendizagem	3e-4 no decoder, 3e-5 no encoder; warmup 3% + cosseno
Batch	12 × 2 de acumulação = 24 efetivo, bf16
Épocas	20; checkpoint da melhor época na validação
Regularização	weight decay, augmentação, pré-treino ImageNet; sem dropout

Entrada no treino: recortes de 512×512. Na validação, no teste e na demo: cena inteira, 1024×1024.

Baseline = slot ref da matriz de experimentos: score 0,658 na validação, a referência de todos os deltas.

Um fator por vez, julgado contra o ruído entre sementes

15 ablações de um único fator · **3 sementes** do baseline: piso de ruído ±0,0068 · **5 folds** agrupados por desastre

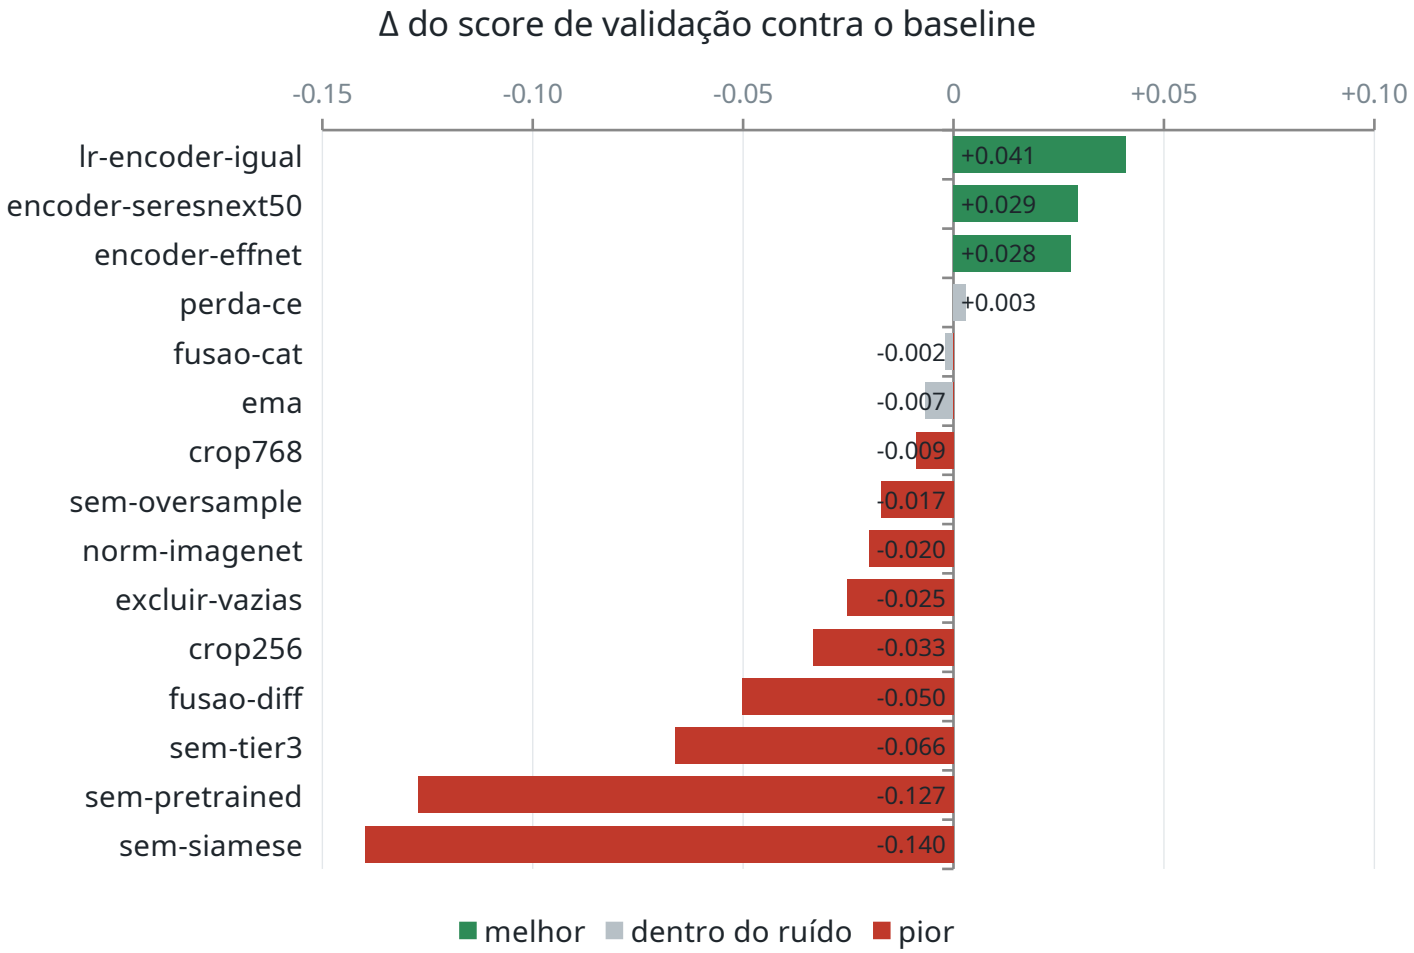
1 · Taxa de aprendizagem do encoder

ALTERAÇÃO	lr_encoder_mult 0,1 → 1,0: o encoder aprende a 3e-4, como o decoder
HIPÓTESE	frear o encoder é prática de fine-tuning longo; em 20 épocas e num domínio longe do ImageNet, ele precisa se adaptar
RESULTADO	validação 0,6994 (+0,0411, 6× o ruído); no teste, 0,6900
DECISÃO	adotado: é o modelo final

2 · Encoder menor

ALTERAÇÃO	resnet34 (25,5 M) → efficientnet_b0 (6,2 M parâmetros)
HIPÓTESE	se faltasse capacidade, o modelo 4× menor perderia
RESULTADO	validação 0,6862 (+0,0279). Empata com seresnext50 (51 M): capacidade não é o gargalo. Rodou com batch 16, não 24
DECISÃO	não adotado sozinho; a combinação com o experimento 1 não foi treinada e fica como próximo passo

Três ganhos reais, três componentes que não se pagam



+0,041

LR do encoder igual à do decoder: o maior ganho, 6× o ruído

−0,140

sem a imagem pós: o sinal de dano vem da comparação entre as datas

−32%

split agrupado por desastre: 0,658 → 0,446. A localização cai 3%; o F1 de dano, 51%

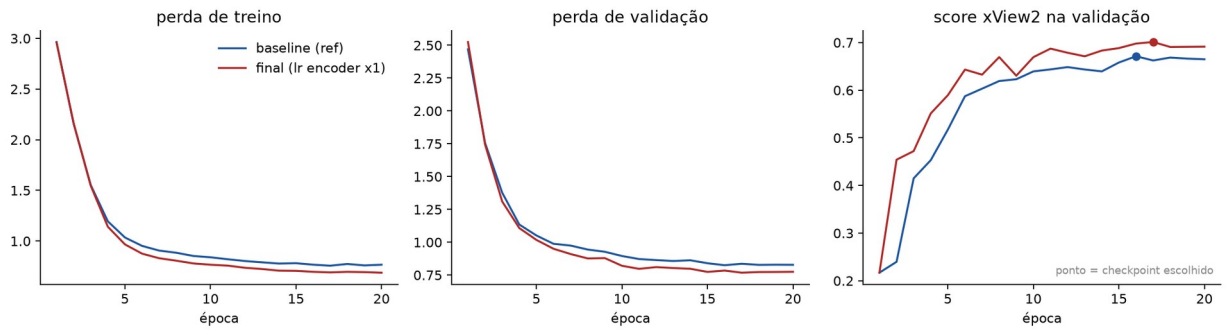
Modelo final no teste, que nenhuma decisão usou

0,690
score xView2 no teste (validação: 0,699)

0,856
F1 de localização: existe edificação no pixel?

0,619
F1 de dano, média harmônica das 4 severidades

0,691
sem as 156 cenas com cópia no treino



Curvas de treino e validação (azul: baseline; vermelho: final). Sem sobreajuste em 20 épocas; o checkpoint é o da melhor época em hold.

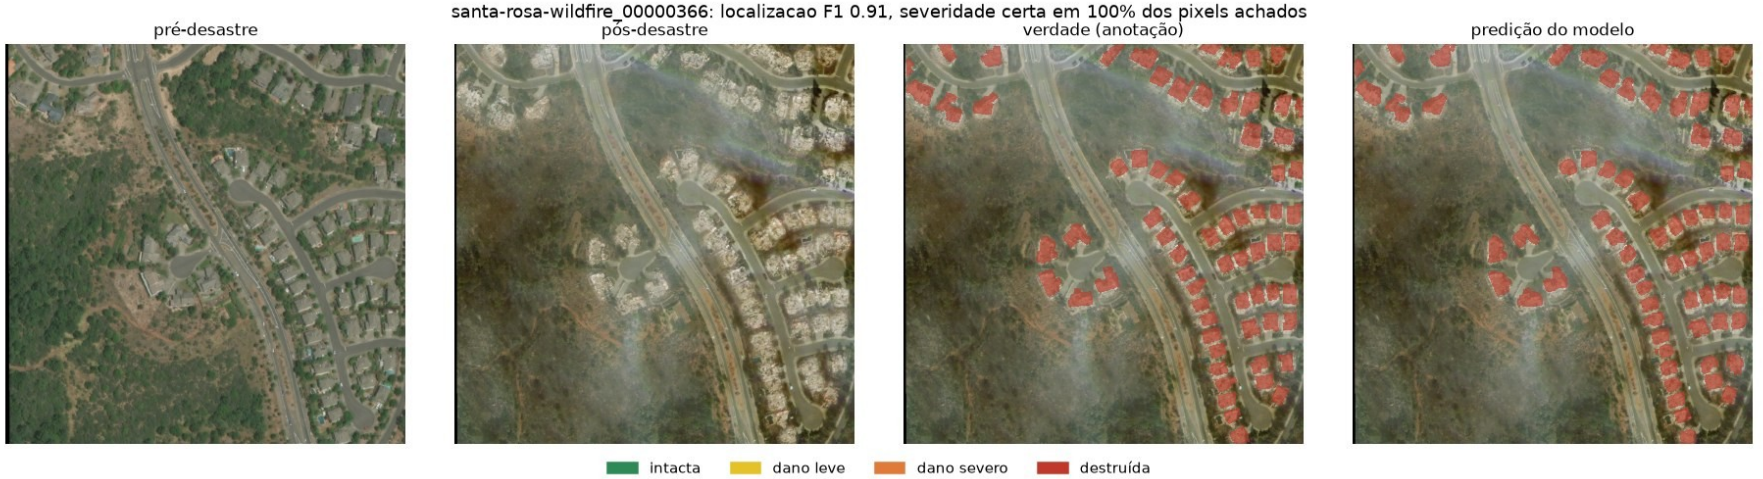
Escolha: maior score de validação, 6× acima do ruído. No teste, perde só 0,009 e segue acima do baseline (0,658).

classe (teste)	precisão	revocação	F1 = Dice	IoU
intacta	0,822	0,806	0,814	0,686
dano leve	0,399	0,455	0,425	0,270
dano severo	0,599	0,710	0,650	0,481
destruída	0,764	0,725	0,744	0,592
fundo	0,992	0,991	0,991	0,983

Acerta a destruição evidente, erra a fronteira entre níveis

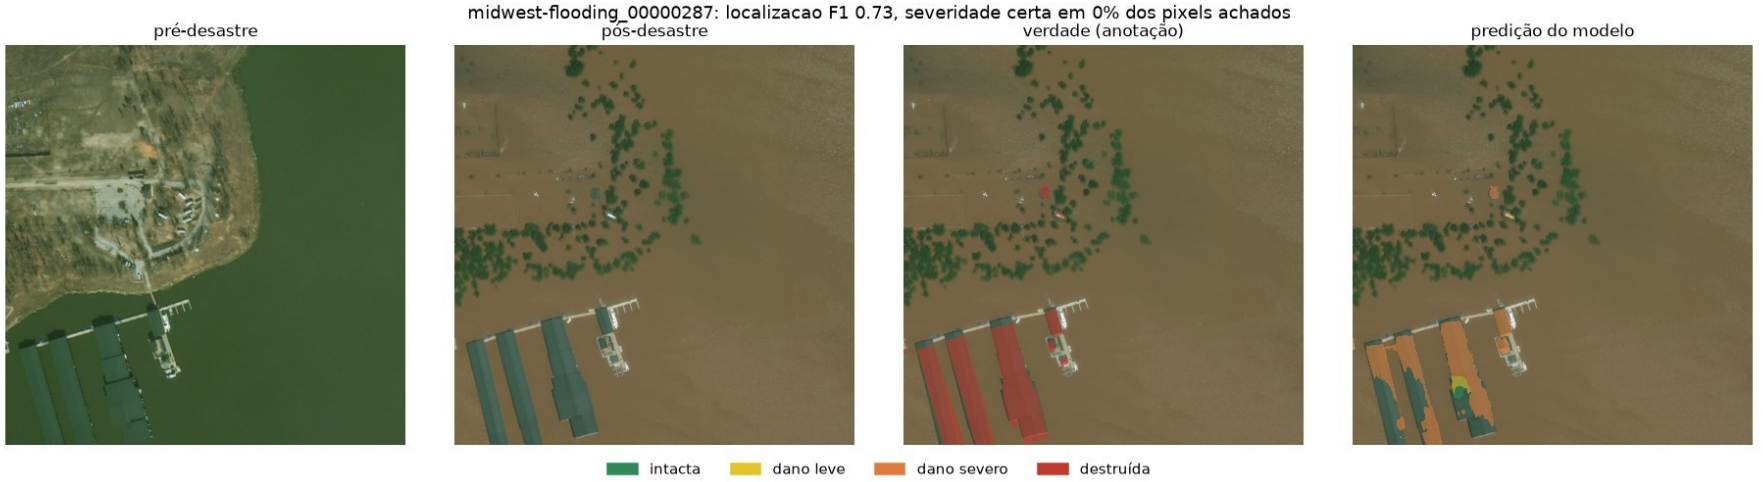
Acerto

Incêndio em Santa Rosa (teste): a destruição é a mudança mais visível entre as datas, e o modelo acerta a severidade de quase todas as casas que encontra.

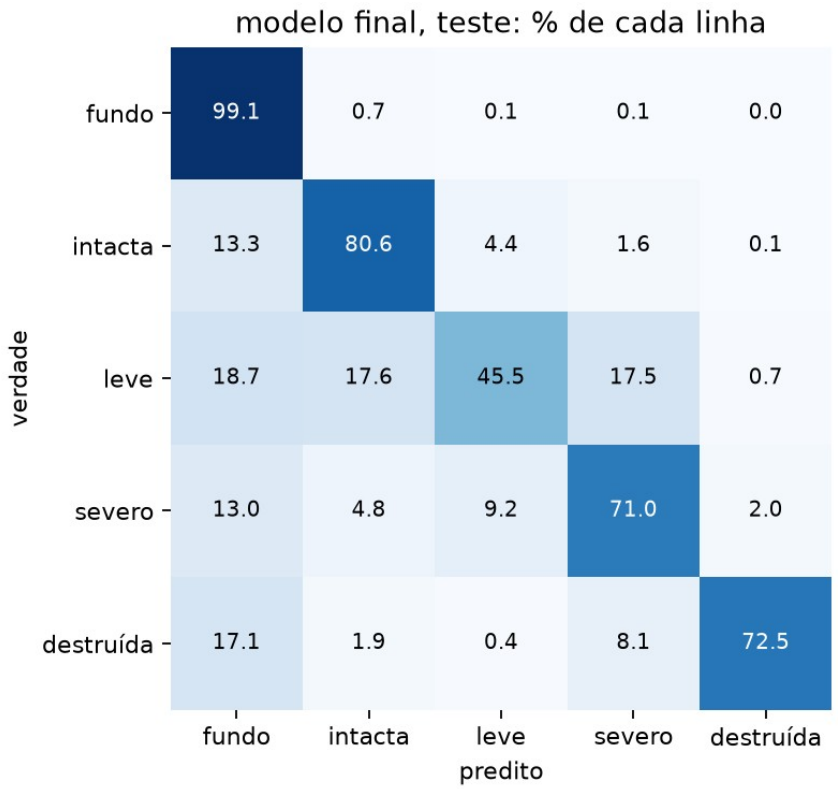


Erro

Enchente no Meio-Oeste dos EUA (teste): galpões alagados, anotados como destruídos, saem como dano severo ou intactos. De cima, um telhado sob a água parece inteiro.



Erros: dano leve ambíguo e prédios não encontrados



Matriz de confusão do modelo final no teste, em % de cada linha verdadeira.

1 O dano leve é ambíguo

Só 45,5% dos pixels de dano leve acertam: 17,6% viram intacta e 17,5% viram severo. A fronteira entre níveis é incerta na própria anotação.

2 Prédios não encontrados

Entre 13,0% e 18,7% dos pixels de cada classe viram fundo: um telhado destruído deixa de parecer edificação.

3 A aparência do dano depende do desastre

O F1 de destruída vai de 0,87 no incêndio a menos de 0,11 nas enchentes. Num desastre fora do treino, o F1 de dano cai 50,6%.

4 Rótulo com ruído

Os polígonos do pós são cópias dos do pré, e a escala de 4 níveis é subjetiva: desalinhamento e ambiguidade viram erro de rótulo.

10 · CONCLUSÃO E LIMITAÇÕES

Localizar transfere; graduar o dano ainda não

Resposta à pergunta

- Localizar edificações: sim. F1 0,856 no teste, com queda de só 3,1% num desastre não visto
- Graduar o dano: em parte. F1 de dano 0,619 no teste, bom para destruída (0,744) e fraco para dano leve (0,425)
- Serve para triagem: separar áreas intactas de destruição evidente, mas não substitui a avaliação humana

O que aprendemos

- Medir o ruído entre sementes antes de ler qualquer delta
- O maior ganho veio da otimização (LR do encoder), não da arquitetura
- $|\Delta|$ na fusão, perda focal e EMA não se pagaram; capacidade não é o gargalo
- O split oficial superestima a generalização em 32%

Limitações e evolução

- 20 épocas, uma semente por ablação, batch efetivo diferente em 4 slots
- Severidade fraca em desastres fora do treino
- Próximo: LR ×1 com efficientnet_b0, mais épocas, split corrigido e voto por edificação

`Demonstração: python scripts/demo.py · notebook: notebooks/03_resultados_e_demo.ipynb`